

Proyecto Business Intelligence

Northwind

INDICE

INTRODUCCION	3
Metodologías de desarrollo de un Data Warehouse	3
Definición de los requerimientos del proyecto	7
Base de datos fuente	7
DISEÑO DE LA ARQUITECTURA BI	12
DISEÑO DEL MODELO MULTIDIMENSIONAL Y ETL	13
Conclusiones	24

INTRODUCCION

Metodologías de desarrollo de un Data Warehouse

Los Data Warehouse toman cada día mayor importancia, a medida que las organizaciones pasan de esquemas de sólo recolección de datos a esquemas de análisis de estos. Sin embargo, a pesar de la gran difusión de los conceptos relacionados con los almacenes de datos, no existe demasiada información objetiva en cuanto a las metodologías para implementarlos, por lo que eventualmente se tendrá que seleccionar la metodología que más se adapte al modelo que se tiene y al resultado que se desea obtener.

Existen muchas metodologías de diseño y construcción de DW. Cada fabricante de software de inteligencia de negocios busca imponer una metodología con sus productos. Sin embargo, se imponen entre la mayoría dos metodologías, la de Kimball y la de Inmon.

En resumen, la metodología de Inmon se basa en conceptos bien conocidos del diseño de bases de datos relacionales, la metodología para la construcción de un sistema de este tipo es la habitual para construir un sistema de información, utilizando las herramientas habituales. Mientras que la de Kimball, se basa en un modelado dimensional (no normalizado).

1.1. Metodología para utilizar

Pensamos que la metodología más acorde al proyecto que se va a desarrollar es la de Kimball, ya que esta nos proporcionará un enfoque de menor a mayor, muy versátil y una serie de herramientas prácticas que ayudan a la implementación de un DW. Es acorde a nuestro proyecto simplemente porque este se basa en obtener un cubo OLAP a partir de una base de datos en específico. Por tanto, se detallará esta metodología a continuación.

1.2. Metodología Kimball

La metodología Kimball propone tener un experto en cada área de la organización que se encargue del diseño de la información más relevante para de esta forma crear los modelos de datos y evitar redundancia de información. Esta se basa en lo que él denomina "Ciclo de Vida Dimensional del Negocio" para la obtención de un Data Warehouse de calidad y consistente. Este ciclo de vida del proyecto de DW, está basado en cuatro principios básicos los cuales se describirán a continuación:

Siempre ofrecer la solución completa.

La finalidad de este principio es que se debe hacer una entrega de un diseño funcional, que cumpla con las expectativas de la organización, se deben entregar herramientas de consulta, aplicaciones gráficas para informes, capacitación y soporte, dependiendo de la tecnología elegida para la implementación. Esto indica que es fundamental brindar todos los elementos necesarios para entregar valor a los usuarios de negocios o en otras palabras, tener un almacén de datos sólido, bien diseñado, con calidad probada, y accesible. También se deberá entregar herramientas de consulta ad hoc, aplicaciones para informes y análisis avanzado, capacitación, soporte, sitio web y documentación

Construir una infraestructura de información adecuada.

Se debe hacer un análisis a fondo de la información a analizar, para así poder generar los modelos adecuados para los data marts. Esto implica diseñar una base de información única, integrada, fácil de usar, de alto rendimiento donde se refleja la amplia gama de requerimientos de negocio identificados en la empresa.

Realizar entregas en incrementos significativos.

Según esta metodología se deben hacer entregas en plazos acordados con la organización teniendo en cuenta que estos no sean tan extensos ni tan cortos. Se recomienda crear el almacén de datos en incrementos entregables en plazos de 6 a 12 meses. Hay que usar el valor de negocio de cada elemento identificado para determinar el orden de aplicación de los incrementos. En esto la metodología se parece a las metodologías ágiles de construcción de software.

Centrarse en el negocio.

Hay que tener un conocimiento profundo acerca del negocio, para poder implementar el modelo a partir de un buen esquema de requerimientos. Esto requiere Identificación de los requerimientos del negocio y su valor asociado, y usar estos esfuerzos para desarrollar relaciones sólidas con el negocio, agudizando el análisis de este y la competencia consultiva de los implementadores.

En resumen, la metodología Kimball es de gran ayuda para este tipo específico de proyectos ya que facilita la creación de un DWH ya que de acuerdo con las misiones de las diferentes áreas de la organización permite el diseño y la construcción de los datamarts específicos, que darán forma al futuro modelo general del sistema.

No obstante, es necesario seguir una serie de tareas en específico para lograr crear un data Warehouse consistente y de calidad, por lo que serán planteados a continuación:

Metodología Ralph Kimball

Selección de Diseño de la Productos e Arquitectura Instalación Definición de Diseño Planificación Modelo Diseño Requisitos del Construcción de del Proyecto Dimensional Físico Procesos ETL Negocio

Implementación Especificación de Aplicaciones Desarrollo de Aplicaciones Mantenimiento y Analiticas Analiticas Crecimiento Gestión del Proyecto

Figura 1: Diagrama de la metodología de Ralph Kimball

De acuerdo con la figura anterior la metodología Kimball se clasifica en 3 caminos los cuales contienen las fases que unidas entre sí conformarán el ciclo de vida de esta, estos caminos son los siguientes:

Tecnología: Esta parte está asociada al diseño de la arquitectura y a la selección de las herramientas informáticas que serán utilizadas en la aplicación de la metodología.

- Datos: En esta capa se implementarán los modelos dimensionales y los modelos de transformación de los datos.
- Aplicaciones de Inteligencia de Negocios: En esta capa se diseñarán las aplicaciones de lógica de negocios que mostrarán los resultados de la metodología planteada para los usuarios de negocio.

Definición de los requerimientos del proyecto

Base de datos fuente

En este caso la base de datos Northwind se encontraba en formato SQL, y para su instalación se debía ejecutar un código mediante una Query, gracias a la cual se creaba cada tabla con sus atributos. En la situación actual, la BD contaba con un total de 13 tablas, las cuales estaban organizadas de la siguiente manera:

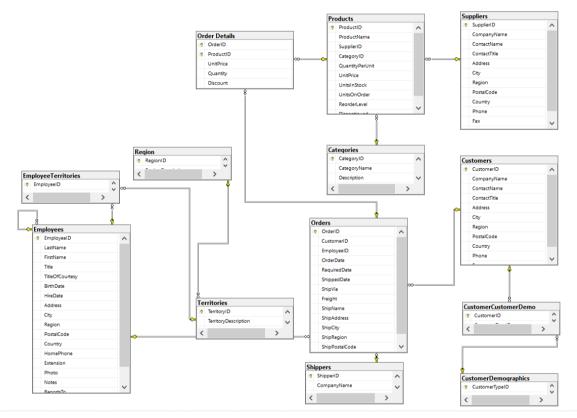


Figura 2. Modelo Crudo Northwind

Modelo Relacional.

En este caso la tabla que más datos importantes contenía fue la de Orders, por lo tanto fue la utilizada para realizar la tabla de hechos del modelo relacional (MR), Utilizando para ello los distintos ID de las otras tablas, que finalmente serán las claves foráneas de la Facts Table, y en cuanto a las tablas restantes, lo que se realizó fue filtrar los datos y eliminar aquellos que no servían, esto con el fin de simplificar el trabajo y mejorar la visualización. A continuación se detalla el modelo relacional final, y como quedaron distribuidas las tablas dentro de la base de datos.

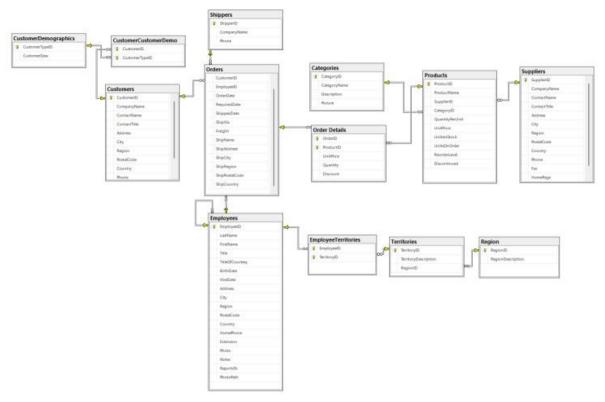


Figura 3. Modelo Relacional

Tabla de hechos

```
/***** Script for SelectTopNRows command from SSMS
SELECT TOP (10) [ProductID]
            ,[CategoryID]
            ,[CustomerID]
            ,[Fecha]
            ,[EmployeeID]
            ,[SupplierID]
            ,[Quantity]
            ,[UnitPrice]
            ,[Total]
      FROM [NorthwindETL].[dbo].[FactTable]
    ProductID
              CategoryID
                       CustomerID
                                   Fecha
                                             EmployeeID
                                                                          UnitPrice
                                                        SupplierID
                                                                  Quantity
                                                                                   Total
              4
                         VINET
                                                        5
                                                                  12
                                                                           14,00
                                                                                   168
1
                                   1996-07-04
                                              5
     11
              5
                         VINET
                                                         20
                                                                  10
                                                                          9.80
                                                                                   98
     42
                                   1996-07-04
                                              5
2
              4
                                                                  5
                                                                                   174
     72
                         VINET
                                   1996-07-04
                                              5
                                                         14
                                                                          34,80
3
              7
                                                        6
                                                                  9
4
     14
                         TOMSP
                                   1996-07-05
                                              6
                                                                           18,60
                                                                                   167
              7
5
     51
                         TOMSP
                                   1996-07-05
                                             6
                                                        24
                                                                  40
                                                                          42,40
                                                                                   1696
6
     41
              8
                         HANAR
                                   1996-07-08 4
                                                         19
                                                                  10
                                                                          7,70
                                                                                   77
              7
7
     51
                         HANAR
                                   1996-07-08 4
                                                         24
                                                                  35
                                                                          42,40
                                                                                   1484
8
     65
              2
                         HANAR
                                   1996-07-08 4
                                                         2
                                                                  15
                                                                           16,80
                                                                                   252
9
     22
                         VICTE
                                   1996-07-08 3
                                                         9
                                                                  6
                                                                           16,80
                                                                                   100
10
     57
                         VICTE
                                   1996-07-08 3
                                                         26
                                                                  15
                                                                           15,60
                                                                                   234
```

Tabla dimensión Tiempo

```
SQLQuery1.sql - LA...B4VFD4S\luisi (51)) 😑 🗙
                                                                      *****/
     /***** Script for SelectTopNRows command from SSMS
   □SELECT TOP (1000) [Fecha]
             ,[AÑO]
             ,[MES]
        FROM [etl-northwind].[dbo].[DIM Tiempo]
100 %

    ⊞ Results

    Messages

                ΑÑΟ
                      MES
     Fecha
     1996-07-04
                1996
                      7
                1996
                      7
2
      1996-07-05
                      7
3
     1996-07-08
                1996
     1996-07-09
                1996
                     7
4
                1996
     1996-07-10
                      7
5
```

Tabla Customer (cliente)



Tabla Supplier (proveedor)

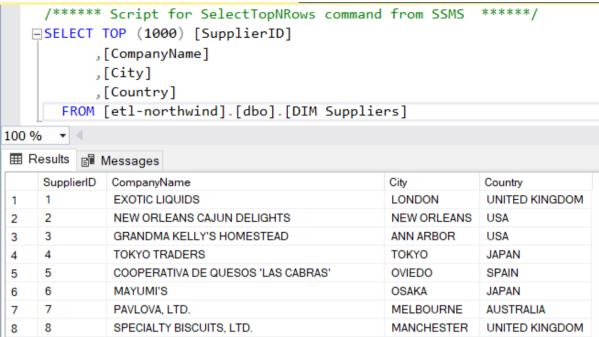


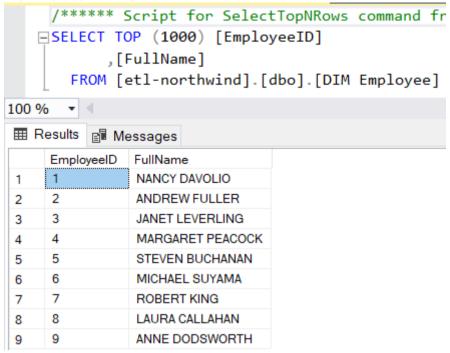
Tabla Product

```
/***** Script for SelectTopNRows command from SSMS
                                                                 *****/

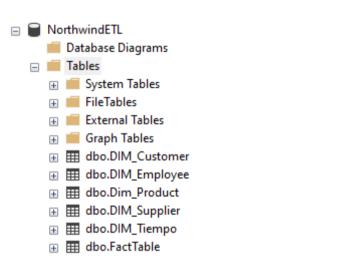
□SELECT TOP (1000) [ProductID]

            ,[Producto]
            ,[Categoria]
       FROM [etl-northwind].[dbo].[DIM Producto]
100 %
       ▼ 4
ProductID
              Producto
                                            Categoria
              CHAI
                                            BEVERAGES
1
     2
              CHANG
                                            BEVERAGES
2
     3
              ANISEED SYRUP
                                            CONDIMENTS
3
     4
              CHEF ANTON'S CAJUN SEASONING
                                            CONDIMENTS
4
     5
              CHEF ANTON'S GUMBO MIX
                                            CONDIMENTS
5
     6
              GRANDMA'S BOYSENBERRY SPREAD
                                            CONDIMENTS
6
     7
7
              UNCLE BOB'S ORGANIC DRIED PEARS
                                            PRODUCE
              NORTHWOODS CRANBERRY SAUCE
8
     8
                                            CONDIMENTS
                                            MEAT/POULTRY
     9
              MISHI KOBE NIKU
9
                                            SEAFOOD
     10
              IKURA
10
```

Tabla Employee (empleado)



Distribución de las tablas en SQL



DISEÑO DE LA ARQUITECTURA BI

Para el desarrollo del proyecto se utilizaron las herramientas que dispone Microsoft SQL Server Management 18.

Microsoft SQL Server Management Studio (SSMS), es un entorno integrado para administrar cualquier infraestructura de SQL, desde SQL Server a Azure SQL Database. SSMS proporciona herramientas para configurar, supervisar y administrar instancias de SQL Server y bases de datos. SSMS es usado para implementar, supervisar y actualizar los componentes de nivel de datos que usan las aplicaciones, además de compilar consultas y scripts.

Microsoft SQL Server está compuesto por:

- **Database Engine**: Es el motor de la base de datos relacional, Es el componente o servicio principal, encargado de administrar la base de datos que da respuestas a las peticiones de uso de las tablas, campos, etc.
- Analysis Services: Es el motor de bases de datos multidimensionales. Este servicio o componente nos permite diseñar, distribuir, explorar los cubos de información y modelos de minería de datos.
- Integration Services: Este servicio permite la implementación de servicios de ETL (Extracción, Transformación y Carga), posibilitando migrar datos de un lugar a otro, hacer conexiones entre diversas bases de datos para realizar las tareas de limpieza, normalización, y estandarización de datos, o simplemente trasladar datos de un lugar a otro.
- Reporting Services: permite diseñar, almacenar y ejecutar reportes que han sido diseñados mediante SQL Server y que acceden a la información de las bases de datos relacionales.

DISEÑO DEL MODELO MULTIDIMENSIONAL Y ETL

Estas son ampliamente utilizadas en el entorno de los Data Warehouse y para aplicaciones encargadas de realizar análisis de procesos en línea. También es habitual que este tipo de bases de datos se empleen usando la información ya contenida en otras bases de datos relacionales. Estos modelos son capaces de procesar la información a gran velocidad, lo que las convierte en una herramienta muy útil para entornos o aplicaciones que requieren obtener respuestas a las consultas inmediatas o en tiempo real.

Un modelo multidimensional se compone de la tabla de hechos y sus dimensiones, que se pueden anotar y ampliar para admitir construcciones de consultas complejas. Los desarrolladores de BI crean cubos para admitir tiempos de respuesta rápida y para proporcionar un único origen de datos para informes empresariales.

Estos cubos de información añaden una nueva dimensión a las tradicionales bases de datos formadas por tablas. Los cubos están formados por dos componentes:

- -Tabla de dimensiones: Aquí se almacenan datos como ítems (nombre del producto, marca, etc.) o fechas
- -Tabla de hechos: Acá se almacena las medidas y las claves que la relaciona con las tablas de dimensiones. Por ejemplo, tamaño en centímetros o valor en euros.

Diseño de capas

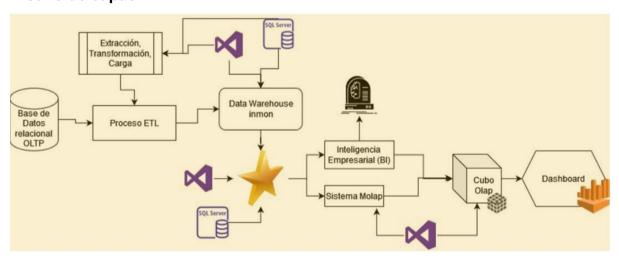


Figura 4: Proceso BI

Como podemos ver en la imagen superior, un proceso BI se inicializa recogiendo los datos almacenados en la base de datos relacional (Datos relacionados entre sí) (se entiende como un conjunto de tablas o relaciones) OLTP (procesamiento de transacciones en línea es un tipo de procesamiento de datos que consiste en ejecutar

una serie de transacciones de manera simultánea en cualquier entorno ya sea de compras, banca en línea, etc.), los cuales mediante una serie de consultas utilizando la herramienta de gestión de base de datos de Microsoft, es posible aislar la información necesaria. Es posible por lo demás encontrar los datos de distintas formas, ya sea en archivos planos u aplicaciones empresariales para el almacenamiento de datos.

El proceso que disecciona la información de origen y la exporta al almacén de datos data Warehouse es el ETL, entendido como extraer, transformar y cargar. Se extrae los elementos necesarios mediante las consultas previamente mencionadas y se exporta la información a la bdd de destino, la cual tendrá la estructura que se estime conveniente, en este caso es de tipo estrella puesto que cada dimensión no tiene relación con las otras, pero todas individualmente forman parte de una tabla de hechos.

Una vez recolectados los datos y trabajados, estos son almacenados en el data Warehouse para su futura utilización en el motor de análisis de datos conocido como cubo OLAP, limpiando así el almacén de datos. Cada cubo distribuye los datos en sus dimensiones y estas se completan con miembros organizados jerárquicamente. Para este caso se utiliza un sistema OLAP de tipo multidimensional ósea Molap, puesto que los análisis se realizan directamente en una base de datos multidimensional mediante estructuras de datos diversas. normalmente multidimensionales conocidas como cubos olap que contienen datos resumidos de grandes bases de datos o sistemas transaccionales (oltp). Este análisis de datos se resume en agilizar la consulta de grandes cantidades de datos.

Por último se realiza la conexión con power bi, que es una solución para el análisis empresarial de datos, con el cual es posible generar los dashboards en los que se verán representados los kpi.

Todo lo expuesto anteriormente se puede representar mediante un esquema por capas nivelada desde la capa 1 a la 5.

- Capa 1: Carga de datos y uso de los mismos mediante la herramienta de administración de bases de datos de Microsoft.

- Capa 2: Realización del Etl, que consiste como ya se explicó en la extracción desde una bd de origen, transformación de los datos y carga en una bd de destino. Se utiliza para esto Visual Studio y Sql Management Studio.
- Capa 3: Trabajo en el cubo, en donde se distribuye la información a usar en cada dimensión (y hechos), jerarquizando la misma si así se estima conveniente.
- Capa 4: Se procesa y crea el cubo, con este será posible acceder a los datos de la forma más eficiente.
- Capa 5: Se crean los reportes en función a lo almacenado en el cubo Olap. Esto para presentar la información de la forma más clara y sin complicaciones posible, facilitando el análisis de los datos y la toma de decisiones y es requerida.

Análisis de la tabla de hechos propuesta.

La tabla de hechos que se utilizará para el modelo multidimensional propuesto consta de 8 hechos los cuales proporcionarán la información correspondiente para dar respuesta a los KPI establecidos, los cuales se enfocan principalmente a los pedidos realizados en la empresa.



Figura 5: Representación de la tabla de hechos.

Análisis de las tablas de dimensiones propuestas

Las tablas de dimensiones propuestas representarán aquello que se quiere almacenar respecto a un tema concreto. En una misma base de datos multidimensional puede haber numerosas tablas de dimensiones asociadas entre sí. Las tablas de dimensiones pueden ser generadas de forma automática, o creadas manualmente por los propios usuarios, lo cual fue lo que sucedió en este caso.

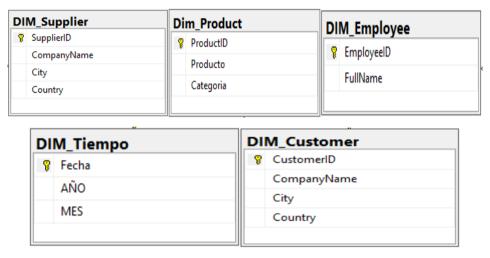


Figura 6: Representación de tablas de dimensiones.

Modelo gráfico de alto nivel

El esquema en estrella, que está compuesto por una tabla central (Facts Table), la que abarca datos cuantitativos, también conocidos como medidas, y una serie de dimensiones que rodea la tabla principal, cada una de estas dimensiones están compuestas por solo una tabla.

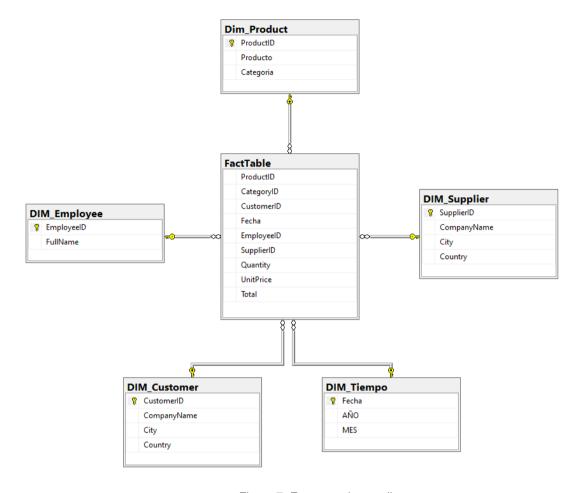


Figura 7: Esquema de estrella.

Prueba de modelo

En este caso, los KPI pedidos fueron los siguientes:

- a) Total de ventas en cada país por vendedor.
- b) Empleado que vende más cantidad de productos.
- c) Compañía que compró más productos.

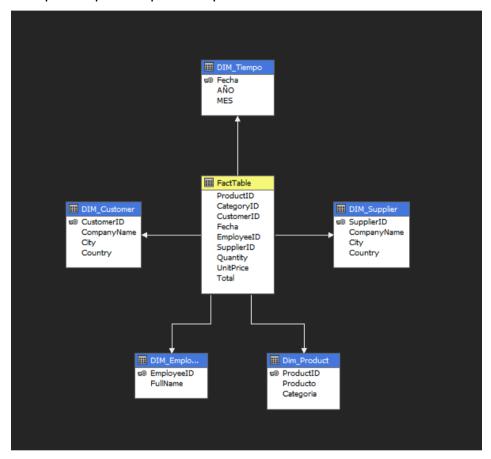


Figura 8: Esquema de estrella previo a la creación del cubo Olap (Visual Studio)

Se puede comprobar a través del modelo multidimensional que los KPI descritos anteriormente son respondidos efectiva y claramente con el modelo.

Diseño Físico y ETL: Extracción, Transformación y Carga.

El proceso de extracción, transformación y carga (ETL) es entendido como una canalización o enfoque de los datos, el cual se usa para recopilar datos de varias fuentes. A continuación, se transforman los datos en función a las reglas de negocio para ser cargados en un almacén de datos. La fase de transformación tiene su desarrollo en un motor especializado, se utilizan frecuentemente tablas temporales para el almacenamiento provisional de los datos que se están transformando, hasta que sean cargados en su lugar de llegada.

Esta transformación conlleva a menudo varias operaciones de filtrado, ordenación, agregación, combinación de datos, limpieza de estos, desaplicación y validación de datos. La idea es ejecutar las tres fases del proceso ETL en paralelo para poder ahorrar tiempo. Ejemplo de esto es que mientras se extraen los datos, se emplea un proceso de transformación sobre los datos ya recibidos y de preparación para su futura carga, así no se espera a que el proceso de extracción termine del todo.

Para poder realizar todo lo descrito se comenzará con la conexión a la fuente de datos original, esto mediante la herramienta Visual Studio. Con los datos ya capturados estos se tratarán en el apartado de flujo de datos, aquí la lógica empresarial será la encargada de hacernos ver cómo proceder y de qué manera llevar los datos a la fuente de destino.

En este punto se resuelve la segunda capa del modelo a presentar, el cual se encarga de preparar los datos crudos provenientes de la base de datos "Northwind" para posteriormente aplicar las transformaciones pertinentes para obtener los datos que se utilizarán para elaborar el cubo OLAP.

Tabla de hechos

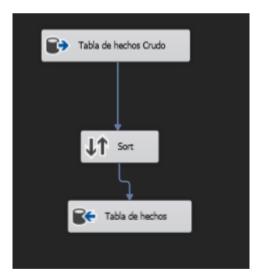


Figura 9: Obtención tabla de hechos en ETL

Para obtener la tabla de hechos necesaria, con los datos consistentes y sin errores, no fué necesario aplicar una gran variedad de transformaciones, puesto que los datos ya venían tratados en la base de datos utilizada, por lo que simplemente se utilizan los objetos para capturar sus datos, ordenarlos y poblar la tabla de hechos que se utilizará posteriormente para el cubo OLAP, asignándole en este apartado sus respectivas claves foráneas.

Dimensiones Producto, Cliente, Supplier, Employee, Tiempo

Para crear las dimensiones pertinentes, se utilizó el mismo proceso en sí para todas las dimensiones, el cual consistió en utilizar los objetos necesarios para la extracción de datos desde la fuente de origen, utilizar el objeto "UPPER" para transformar los datos a mayúsculas y así agilizar las consultas en el resultado final, el objeto "Columna derivada" para cambiar strings en ciertos apartados y finalmente el objeto "Destino" para crear la dimensión y poblarse con los datos listos para ser procesados.

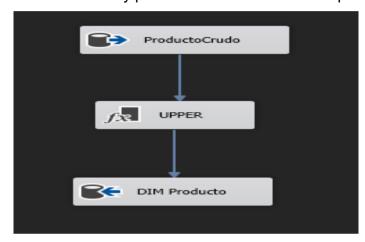


Figura 10: Dimensión Producto

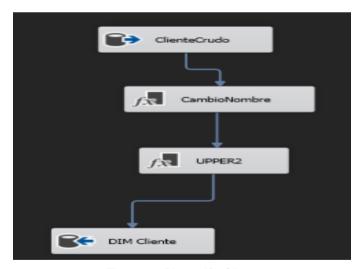


Figura 11: Dimensión Cliente

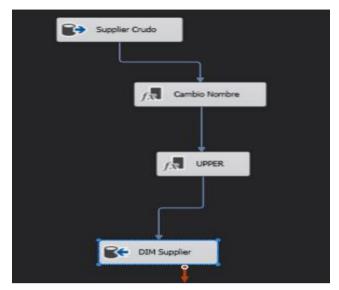


Figura 12: Dimensión Supplier

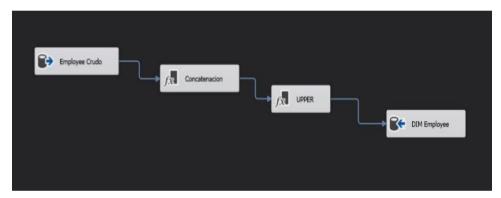


Figura 13: Dimensión Employee

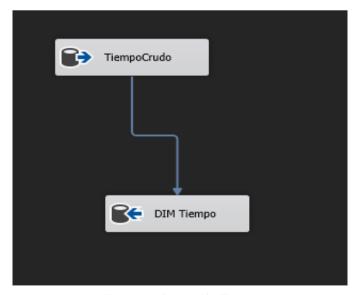


Figura 14: Dimensión Tiempo

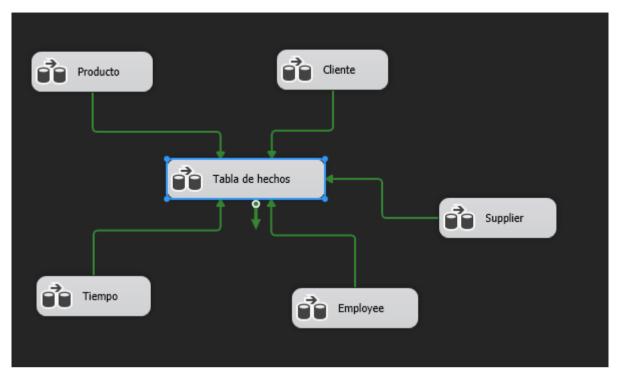


Figura 15: Modelo Estrella Final.

Diseño del cubo

Para la implementación del cubo se utilizó la herramienta Analysis Services de SQL server, la cual podemos encontrar en Visual Studio 2019, gracias a esta herramienta podemos cargar la tabla de hechos y las dimensiones con los datos que están incluidos en el Data warehouse.

El explorador de soluciones de este proyecto está compuesto de la siguiente manera:

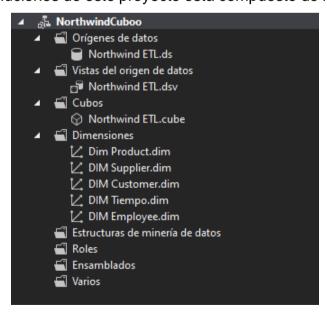
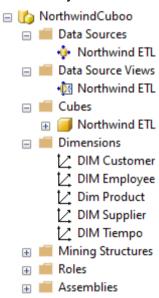


Figura 16: Vista Cubo Olap Visual

- **Orígenes de datos:** Es el primer paso que debemos realizar para poder crear el cubo, es donde se cargan los datos de origen provenientes de SQL Server.
- Vistas del origen de datos: Podemos ver la estructura que tendrá nuestro cubo, seleccionando las tablas correspondientes a las dimensiones y a la tabla de hechos.
- Cubos: Es donde toma forma el cubo, se debe señalar qué tabla es la de hechos y cuáles son las dimensiones. El modelo del cubo ya creado se puede ver en la figura N°8.
- **Dimensiones:** en este apartado podemos revisar las estructuras de las dimensiones creadas por el asistente.

Una vez realizados los procedimientos antes mencionados, queda crear una base de datos en el SQL server, en el motor de Analysis Services. A continuación, se presenta el cubo ya creado en el motor de Analysis Services.



Reporte de datos

Para la visualización, la herramienta utilizada fue Power BI de Microsoft, la cual permite realizar vistas tipo dashboard para así tener una mejor visualización de datos. En este caso, realizamos la siguiente dashboard con los 3 KPI descritos anteriormente:

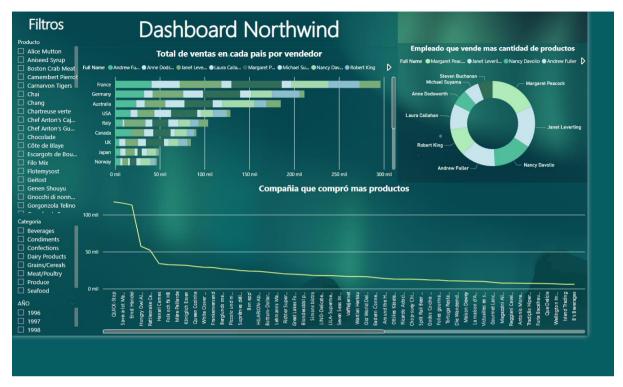


Figura 15: Reportes Power Bi

En la cual podemos observar los distintos gráficos que dan a conocer los datos y estadísticas solicitadas. Además de ello, tenemos en el lado izquierdo los filtros de producto, categoría y año, que nos ayudarán a dar una mejor visualización del modelo de datos confeccionado.

Conclusiones

De manera general, la realización de este proyecto de Business Intelligence, nos acercó de manera explosiva a lo que existe hoy en día en el mercado, aplicando conceptos clave en su desarrollo tales como el modelo relacional, del cual podemos rescatar la simplicidad de datos que finalmente quedaron enlazados, siguiendo con el diseño de capas, en donde vimos una clara secuencia de capas enlazadas una con la otra, pasando por el proceso ETL, el cual a nuestro parecer es la parte fundamental del proyecto, ya que dependiendo de si cumplimos con los estándares correcto, nuestros pasos siguientes tendrán éxito o no. Finalmente, en cuanto al diseño del cubo, nos encontramos con ciertos inconvenientes que se resolvieron rápidamente. En cuanto a la visualización de datos, creemos que la manera en la que se despliegan los datos es de un fácil entendimiento tanto como para desarrollador y consumidor, esto debido a que utilizamos una temática y paleta de colores coincidentes.

En resumen, el realizar un proyecto de Business Intelligence requiere un estricto procedimiento para cada una de sus fases, esto es debido a que cualquier error en su desarrollo puede llevar a una visualización mal ejecutada.